Identificação de Termo Fonte em Equações Parabólicas via Physics-Informed Neural Networks

Formulação Matemática e Descrição Computacional

Mateus de Jesus Mendes

Fevereiro de 2026

Resumo

Este documento apresenta a formulação matemática rigorosa do problema inverso de identificação de termo fonte em equações parabólicas, abordado por meio de Physics-Informed Neural Networks (PINNs) [1, 2]. O problema consiste em, dadas observações (possivelmente parciais e ruidosas) da solução $u(x,t)$ da equação do calor com difusividade conhecida $\alpha > 0$, recuperar o campo $f(x,t)$ que atua como fonte na equação. São descritos os fundamentos funcionais do problema direto e inverso, a arquitetura de dupla rede (u_{NN}, f_{NN}), a função de perda multi-componente e o protocolo de cinco experimentos com soluções analíticas verificadas, cobrindo cenários de crescente dificuldade: decaimento exponencial, múltiplos modos de Fourier, oscilação periódica, saturação temporal e robustez a ruído.

Sumário

1 Fundamentos Matemáticos **2**
1.1 Espaços Funcionais e Notação 2
1.2 Formulação do Problema Direto 2
1.3 Formulação do Problema Inverso 3

2 Physics-Informed Neural Networks (PINNs) **3**
2.1 Arquitetura de Dupla Rede 3
2.2 Diferenciação Automática e Resíduo da PDE 4
2.3 Função de Perda Multi-Componente 4
2.4 Protocolo de Treinamento 6

3 Experimentos: Formulação Detalhada **6**
3.1 Experimento 1 – Baseline: Decaimento Exponencial (modo único) . . . 6
3.2 Experimento 2 – Dois Modos de Fourier 7
3.3 Experimento 3 – Oscilação Periódica (Manufactured Solution) 7
3.4 Experimento 4 – Crescimento com Saturação (Manufactured Solution) . 8
3.5 Experimento 5 – Robustez a Ruído 8

4 Análise Comparativa dos Experimentos **9**
4.1 Condição de Identificabilidade 10

5 Implementação Computacional **10**
5.1 Estrutura do Projeto 10
5.2 Verificação das Soluções Analíticas 10
5.3 Hiperparâmetros de Treinamento 11

Referências **11**

A Teoremas de Existência Detalhados **13**
A.1 Problema Direto – Lions–Magenes 13
A.2 Caráter Mal-Posto do Problema Inverso 13

1 Fundamentos Matemáticos

1.1 Espaços Funcionais e Notação

Seja $\Omega = (0,1) \subset \mathbb{R}$ e $T > 0$ um horizonte temporal fixo. Denotamos o cilindro espaço-temporal por $Q_T = \Omega \times (0,T]$.

Definição 1.1 (Espaços de Sobolev [3, 4])**.**

$$\begin{aligned} L^2(\Omega) &= \left\{ v : \Omega \to \mathbb{R} \;\middle|\; \|v\|_{L^2}^2 = \textstyle\int_\Omega |v|^2 \, dx < \infty \right\}, \\ H^1(\Omega) &= \left\{ v \in L^2(\Omega) \;\middle|\; v_x \in L^2(\Omega) \right\}, \\ H_0^1(\Omega) &= \left\{ v \in H^1(\Omega) \;\middle|\; v\big|_{\partial\Omega} = 0 \right\}. \end{aligned}$$

Definição 1.2 (Espaços Parabólicos [5, 3])**.**

$$L^2(0,T;\, H_0^1(\Omega)) = \left\{ v : (0,T) \to H_0^1(\Omega) \;\middle|\; \int_0^T \|v(t)\|_{H^1}^2 \, dt < \infty \right\}.$$

1.2 Formulação do Problema Direto

Problema 1.1 (Equação do Calor com Termo Fonte)**.** Dados $\alpha > 0$ (constante conhecida), $f \in L^2(Q_T)$ e condições de contorno/inicial homogêneas, encontrar $u : Q_T \to \mathbb{R}$ tal que:

$$\begin{cases} u_t(x,t) = \alpha\, u_{xx}(x,t) + f(x,t), & (x,t) \in Q_T, \\ u(0,t) = u(1,t) = 0, & t \in (0,T], \\ u(x,0) = 0, & x \in \Omega. \end{cases} \tag{1}$$

Observação 1.1. *A condição inicial homogênea $u(x,0) = 0$ é adotada em todos os experimentos implementados. O caso $u(x,0) \neq 0$ pode ser tratado com o mesmo arcabouço, incorporando-se o termo de condição inicial diretamente na função de perda.*

Teorema 1.1 (Existência e Unicidade – Problema Direto [5, 3])**.** *Para $\alpha > 0$ constante e $f \in L^2(Q_T)$, existe uma única solução fraca*

$$u \;\in\; L^2(0,T;\, H_0^1(\Omega)) \cap C([0,T];\, L^2(\Omega))$$

satisfazendo, para quase todo $t \in (0,T]$ e para todo $v \in H_0^1(\Omega)$:

$$\int_\Omega u_t \, v \, dx + \alpha \int_\Omega u_x \, v_x \, dx = \int_\Omega f \, v \, dx, \qquad u(\cdot,0) = 0. \tag{2}$$

Demonstração. Segue do Teorema de Lions–Magenes aplicado à forma bilinear parabólica $a(u,v) = \alpha \int_\Omega u_x v_x \, dx$, coerciva e contínua em $H_0^1(\Omega)$. □ □

Solução Analítica via Separação de Variáveis [3, 6, 7]. Para $f(x,t)$ expansível em série de senos,

$$f(x,t) = \sum_{n=1}^{\infty} F_n(t) \, \sin(n\pi x),$$

a solução de (1) é obtida modalmente. O modo n satisfaz o problema de Cauchy escalar:

$$g_n'(t) + \lambda_n\, g_n(t) = F_n(t), \qquad g_n(0) = 0, \qquad \lambda_n = \alpha(n\pi)^2, \tag{3}$$

com solução geral $g_n(t) = \int_0^t e^{-\lambda_n(t-s)} F_n(s)\, ds$ [8, 6]. Para $F_n(t) = A\, e^{-\mu t}$ com $\lambda_n \neq \mu$:

$$g_n(t) = \frac{A}{\lambda_n - \mu}\big(e^{-\mu t} - e^{-\lambda_n t}\big). \tag{4}$$

A solução completa é $u(x,t) = \sum_{n=1}^{\infty} g_n(t)\, \sin(n\pi x)$.

1.3 Formulação do Problema Inverso

Problema 1.2 (Identificação do Termo Fonte [9, 10])**.** Dado um conjunto de observações

$$\mathcal{D} = \big\{(x_i, t_j,\, u_{\text{obs}}(x_i, t_j)) : i = 1, \ldots, N_x,\ j = 1, \ldots, N_t\big\},$$

determinar $f^*(x,t)$ tal que a solução $u(\cdot\,;\, f^*)$ do Problema 1.1 seja compatível com as observações em $\mathcal{D}$.

Definição 1.3 (Operador Solução)**.** Define-se o operador não-linear

$$\mathcal{S} : L^2(Q_T) \longrightarrow L^2(Q_T), \qquad \mathcal{S}(f) = u(\,\cdot\,;\, f),$$

onde u é a solução do Problema 1.1 com fonte f.

Teorema 1.2 (Continuidade de $\mathcal{S}$ [9])**.** *O operador $\mathcal{S}$ é Lipschitz contínuo: existe $L > 0$ tal que*

$$\|\mathcal{S}(f_1) - \mathcal{S}(f_2)\|_{L^2(Q_T)} \;\leq\; L\, \|f_1 - f_2\|_{L^2(Q_T)}\,.$$

Observação 1.2 (Degenerescência de Escala [11, 1])**.** *Quando $u(x,0) = 0$ e $u(0,t) = u(1,t) = 0$, o sistema (1) é invariante pela transformação $(u,f) \mapsto (ku, kf)$ para qualquer $k \in \mathbb{R}$. Consequentemente, sem observações interiores de u com magnitude absoluta conhecida, a PINN pode convergir para uma solução (ku^*, kf^*) com k arbitrário — mesmo que f_{NN} convirja para o formato correto de f^*. Esta degenerescência é quebrada incluindo-se o termo $\mathcal{L}_{u\text{-}obs}$ na função de perda (ver Seção 2.3).*

2 Physics-Informed Neural Networks (PINNs)

2.1 Arquitetura de Dupla Rede

A abordagem adotada parametriza simultaneamente a solução u e o termo fonte f por meio de duas redes neurais independentes [1, 12]:

$$u_{\text{NN}}(x,t;\, \theta_u) : [0,1] \times [0,T] \to \mathbb{R}, \qquad f_{\text{NN}}(x,t;\, \theta_f) : [0,1] \times [0,T] \to \mathbb{R}, \tag{5}$$

onde θ_u e θ_f denotam os vetores de pesos treináveis.

Arquitetura de u_{NN} (rede $\mathcal{N}_u$) [1, 12]:

- Entrada: $(x,t) \in [0,1]^2$, normalizada para $[-1,1]^2$
- Camadas ocultas: 4×50 neurônios, ativação tanh

- Saída escalar: $u_{\text{NN}}(x,t) \in \mathbb{R}$

Arquitetura de f_{NN} (rede $\mathcal{N}_f$):

- Entrada: $(x,t) \in [0,1]^2$, normalizada para $[-1,1]^2$
- Camadas ocultas: 3×50 neurônios, ativação tanh
- Saída escalar: $f_{\text{NN}}(x,t) \in \mathbb{R}$

A normalização da entrada é definida por:

$$\hat{x} = 2x - 1, \qquad \hat{t} = 2t/T - 1, \tag{6}$$

o que melhora o condicionamento do problema de otimização [12].

A expressividade das redes $\mathcal{N}_u$ e $\mathcal{N}_f$ é garantida pelo Teorema de Aproximação Universal [13, 14]: redes *feedforward* com pelo menos uma camada oculta de largura suficiente e ativação não polinomial podem aproximar uniformemente qualquer função contínua em compactos.

2.2 Diferenciação Automática e Resíduo da PDE

As derivadas de u_{NN} são calculadas exatamente por diferenciação automática (*autograd*) do PyTorch [15], sem erros de truncamento [16]:

$$u_t = \frac{\partial u_{\text{NN}}}{\partial t}, \qquad u_x = \frac{\partial u_{\text{NN}}}{\partial x}, \qquad u_{xx} = \frac{\partial^2 u_{\text{NN}}}{\partial x^2}. \tag{7}$$

O resíduo pontual da PDE é então:

$$\mathcal{R}(x,t;\,\theta_u,\theta_f) = \frac{\partial u_{\text{NN}}}{\partial t}(x,t) - \alpha\,\frac{\partial^2 u_{\text{NN}}}{\partial x^2}(x,t) - f_{\text{NN}}(x,t). \tag{8}$$

Em termos de código PyTorch:

Listing 1: Cálculo do resíduo da PDE via autograd

```python
def pde_residual(self, xt: torch.Tensor) -> torch.Tensor:
    xt = xt.clone().detach().requires_grad_(True)
    u  = self.u_net(self._normalize(xt))    # u_NN(x,t)
    f  = self.f_net(self._normalize(xt))    # f_NN(x,t)

    grad_u = torch.autograd.grad(
        u.sum(), xt, create_graph=True, retain_graph=True
    )[0]
    u_x = grad_u[:, 0:1]    # du/dx
    u_t = grad_u[:, 1:2]    # du/dt

    u_xx = torch.autograd.grad(
        u_x.sum(), xt, create_graph=True, retain_graph=True
    )[0][:, 0:1]              # d^2u/dx^2

    return u_t - self.alpha * u_xx - f
```

2.3 Função de Perda Multi-Componente

A função de perda total é uma combinação ponderada de cinco termos [1, 17, 18, 19]:

$$\boxed{\mathcal{L}_{\text{total}}(\theta_u,\theta_f) = w_{\text{BC}}\,\mathcal{L}_{\text{BC}} + w_{\text{PDE}}\,\mathcal{L}_{\text{PDE}} + w_{\text{reg}}\,\mathcal{L}_{\text{reg}} + w_u\,\mathcal{L}_{u\text{-obs}} + w_f\,\mathcal{L}_{f\text{-obs}}} \tag{9}$$

Componentes da Loss

1. Condições de Contorno e Condição Inicial ($\mathcal{L}_{\text{BC}}$):

$$\mathcal{L}_{\text{BC}} = \frac{1}{N_{\text{BC}}} \sum_{k=1}^{N_{\text{BC}}} \big(u_{\text{NN}}(x_k, t_k) - u_{\text{BC}}(x_k, t_k)\big)^2, \tag{10}$$

onde o conjunto de pontos de contorno inclui $u(0,t) = u(1,t) = 0$ e $u(x,0) = 0$.

2. Resíduo da PDE ($\mathcal{L}_{\text{PDE}}$):

$$\mathcal{L}_{\text{PDE}} = \frac{1}{N_{\text{PDE}}} \sum_{k=1}^{N_{\text{PDE}}} \big[\mathcal{R}(x_k, t_k;\, \theta_u, \theta_f)\big]^2, \tag{11}$$

avaliado em $N_{\text{PDE}} = 150 \times 150 = 22\,500$ pontos de colocação interiores em malha uniforme [20, 1].

3. Regularização de Suavidade de f ($\mathcal{L}_{\text{reg}}$):

$$\mathcal{L}_{\text{reg}} = \frac{1}{N_{\text{PDE}}} \sum_{k=1}^{N_{\text{PDE}}} \left\|\nabla_{(x,t)}\, f_{\text{NN}}(x_k, t_k)\right\|^2, \tag{12}$$

penalizando variações bruscas em f_{NN} sem restringir sua magnitude [21, 22].

4. Observações Interiores de u ($\mathcal{L}_{u\text{-obs}}$):

$$\mathcal{L}_{u\text{-obs}} = \frac{1}{N_u} \sum_{k=1}^{N_u} \big(u_{\text{NN}}(x_k, t_k) - u^*(x_k, t_k)\big)^2. \tag{13}$$

Observação 2.1 (Papel Essencial de $\mathcal{L}_{u\text{-obs}}$)**.** *Este termo é* ***indispensável*** *para resolver a degenerescência de escala descrita na Observação 1.2. Sem ele, a rede converge para* $(ku_{\text{NN}},\, kf_{\text{NN}})$ *com k arbitrário. Os $N_u = 60 \times 60 = 3\,600$ pontos são dispostos em grade uniforme (excluindo bordas, já cobertas por $\mathcal{L}_{\text{BC}}$), garantindo cobertura homogênea do domínio e evitando regiões sem ancoragem de escala.*

5. Observações Diretas de f ($\mathcal{L}_{f\text{-obs}}$):

$$\mathcal{L}_{f\text{-obs}} = \frac{1}{N_f} \sum_{k=1}^{N_f} \big(f_{\text{NN}}(x_k, t_k) - f^*(x_k, t_k)\big)^2, \tag{14}$$

com $N_f = 200$ pontos amostrados aleatoriamente. Este termo simula observações indiretas (ou diretas) do termo fonte.

Pesos Padrão [22, 23]

Componente	Peso padrão	Justificativa
w_{BC}	100.0	Cumprimento estrito das BCs
w_{PDE}	10.0	Satisfação da equação governante
w_{reg}	10^{-4}	Suavidade de f_{NN}
w_u	100.0	Ancoragem de escala/forma de u
w_f	50.0	Supervisão direta em f

2.4 Protocolo de Treinamento

- **Otimizador:** Adam [24] ($\beta_1 = 0.9$, $\beta_2 = 0.999$), *learning rate* inicial $\eta_0 = 10^{-3}$
- **Scheduler:** Decaimento exponencial com fator $\gamma = 0.9$ a cada 2 000 passos
- **Passos de treinamento:** 8 000
- **Tamanho de batch:** 1 000 pontos PDE por passo (os N_u e N_f são amostrados em mini-batches quando $N > 1\,000$)
- **Métricas monitoradas:** erro L^2 relativo em u e f, calculados em malha de teste 200×200

Erro L^2 relativo (métrica principal) [1, 25]:

$$E_f^{L^2} = \frac{\sqrt{\sum_{i,j}\big(f_{\mathrm{NN}}(x_i,t_j) - f^*(x_i,t_j)\big)^2}}{\sqrt{\sum_{i,j}\big(f^*(x_i,t_j)\big)^2}}, \qquad E_u^{L^2} = \frac{\sqrt{\sum_{i,j}\big(u_{\mathrm{NN}}(x_i,t_j) - u^*(x_i,t_j)\big)^2}}{\sqrt{\sum_{i,j}\big(u^*(x_i,t_j)\big)^2}}. \tag{15}$$

3 Experimentos: Formulação Detalhada

Todos os experimentos compartilham o mesmo domínio $Q_T = (0,1) \times (0,1]$, difusividade $\alpha = 1$ (conhecida) e condição inicial $u(x,0) = 0$. As soluções analíticas (u^*, f^*) foram *verificadas numericamente* por diferenças finitas de segunda ordem, com resíduo máximo $|\mathcal{R}| < 10^{-4}$ em todos os casos.

3.1 Experimento 1 – Baseline: Decaimento Exponencial (modo único)

Objetivo

Validar a capacidade da PINN de identificar um termo fonte de modo único e estrutura simples, com dados completos e sem ruído. Serve como caso de referência para todos os experimentos seguintes.

Par (f^*, u^*) Exato

$$f^*(x,t) = \sin(\pi x)\, e^{-t}, \tag{16}$$

$$u^*(x,t) = \frac{1}{\alpha\pi^2 - 1}\big(e^{-t} - e^{-\alpha\pi^2 t}\big)\, \sin(\pi x). \tag{17}$$

Para $\alpha = 1$: $\lambda_1 = \pi^2 \approx 9.870$, $C_1 = 1/(\pi^2 - 1) \approx 0.1127$, portanto

$$u^*(x,t) = 0.1127\,\big(e^{-t} - e^{-9.870\,t}\big)\, \sin(\pi x).$$

Observação 3.1 (Derivação por Variação de Parâmetros)**.** *O modo $n = 1$ da solução satisfaz a equação escalar $g_1' + \pi^2 g_1 = e^{-t}$, $g_1(0) = 0$. A solução particular é Ae^{-t} com $A(-1) = -\pi^2 A + 1$, logo $A = 1/(\pi^2 - 1)$. A solução homogênea $Ce^{-\pi^2 t}$ é determinada pela CI: $C = -A$. Portanto $g_1(t) = A(e^{-t} - e^{-\pi^2 t})$, conforme (4).*

Dados de Treinamento

Conjunto	N	Descrição
Pontos PDE	$150 \times 150 = 22\,500$	Malha uniforme interior
Contorno/CI (N_{BC})	$\sim 1\,000$	BCs laterais + $u(x,0) = 0$
Obs. de f (N_f)	200	Amostras aleatórias de f^*
Obs. de u (N_u)	$60 \times 60 = 3\,600$	Grade uniforme de u^*
Teste	$200 \times 200 = 40\,000$	Malha fina para métricas

Critérios de Sucesso

$$E_f^{L^2} < 5 \times 10^{-3}, \qquad E_u^{L^2} < 5 \times 10^{-2}, \qquad \|\mathcal{R}\|_\infty < 10^{-3}.$$

3.2 Experimento 2 – Dois Modos de Fourier

Objetivo

Verificar se a PINN identifica f^* quando este apresenta estrutura espacial mais rica, com dois modos de Fourier independentes.

Par (f^*, u^*) Exato

$$f^*(x,t) = \big[\sin(\pi x) + 0.5\sin(2\pi x)\big]\, e^{-2t}. \tag{18}$$

A solução é obtida por superposição dos modos $n = 1$ e $n = 2$ com decaimento temporal e^{-2t} ($\mu = 2$):

$$\lambda_1 = \pi^2, \qquad C_1 = \frac{1}{\lambda_1 - 2} \approx 0.1271, \tag{19}$$

$$\lambda_2 = 4\pi^2, \qquad C_2 = \frac{0.5}{\lambda_2 - 2} \approx 0.01334, \tag{20}$$

$$u^*(x,t) = C_1\big(e^{-2t} - e^{-\lambda_1 t}\big)\,\sin(\pi x) + C_2\big(e^{-2t} - e^{-\lambda_2 t}\big)\,\sin(2\pi x). \tag{21}$$

Aspecto Central

O modo $n = 2$ decai muito rapidamente ($e^{-4\pi^2 t} \approx e^{-39.5t}$) e se torna numericamente insignificante para $t \gtrsim 0.1$. A PINN deve capturar este comportamento transitório rápido.

3.3 Experimento 3 – Oscilação Periódica (Manufactured Solution)

Objetivo

Identificar f^* quando o sistema exibe variação temporal periódica, testando a capacidade da rede de aprender dependências temporais oscilatórias.

Par (f^*, u^*) por Manufactured Solution

Escolhe-se u^* e deriva-se f^* diretamente da PDE:

$$u^*(x,t) = 0.05\,\sin(\pi x)\,(1-\cos(2\pi t)), \tag{22}$$

$$\begin{aligned} f^*(x,t) &= u_t^* - \alpha\, u_{xx}^* \\ &= \sin(\pi x)\,\big[0.1\pi\sin(2\pi t) + 0.05\pi^2(1-\cos(2\pi t))\big]. \end{aligned} \tag{23}$$

Observação 3.2 (Método de Manufactured Solutions [26, 27])**.** *A abordagem* manufactured solution *consiste em fixar a forma desejada para u^*, calcular analiticamente $f^* = u_t^* - \alpha u_{xx}^*$ e verificar que o par (u^*, f^*) satisfaz a PDE por construção. Este método garante a existência de uma solução exata verificável.*

Propriedades

- $u^*(x,0) = 0$ (CI satisfeita por $1-\cos(0) = 0$)
- $u^*(0,t) = u^*(1,t) = 0$ (BCs satisfeitas por $\sin(0) = \sin(\pi) = 0$)
- Amplitude máxima: $|u^*| \le 0.1$; amplitude de f^*: ≈ 0.81
- f^* é periódico em t com período $T = 1$

3.4 Experimento 4 – Crescimento com Saturação (Manufactured Solution)

Objetivo

Identificar f^* num regime de transição temporal: a fonte começa com estrutura de difusão dominante e evolui para saturação. O f^* é não-monotono em t.

Par (f^*, u^*) por Manufactured Solution

$$u^*(x,t) = 0.1\,\sin(\pi x)\,(1-e^{-2t}), \tag{24}$$

$$\begin{aligned} f^*(x,t) &= u_t^* - \alpha\, u_{xx}^* \\ &= \sin(\pi x)\,\big[0.2\,e^{-2t} + 0.1\pi^2(1-e^{-2t})\big]. \end{aligned} \tag{25}$$

Comportamento de f^*

$$f^*(x,0) = 0.2\,\sin(\pi x), \qquad \lim_{t\to\infty} f^*(x,t) = 0.1\pi^2\,\sin(\pi x) \approx 0.987\,\sin(\pi x).$$

Para t pequeno, o termo $0.2e^{-2t}$ domina; para t grande, o termo difusivo $0.1\pi^2(1-e^{-2t})$ domina. A mudança de regime ocorre em torno de $t^* = -\frac{1}{2}\ln(0.5\pi^2) \approx 0.8$.

3.5 Experimento 5 – Robustez a Ruído

Objetivo

Avaliar a estabilidade da identificação sob contaminação gaussiana dos dados de treinamento.

Sistema Base

Idêntico ao Experimento 1: $f^*(x,t) = \sin(\pi x)e^{-t}$.

Modelo de Ruído

Os dados observados são contaminados [28]:

$$u_{\text{obs}}(x_i, t_j) = u^*(x_i, t_j) + \eta_{ij}, \qquad \eta_{ij} \sim \mathcal{N}(0, \sigma^2), \tag{26}$$

com nível de ruído relativo:

$$\sigma = \beta \cdot \text{std}(u^*|_{\mathcal{D}}), \tag{27}$$

onde $\beta \in \{0.01,\ 0.05,\ 0.10\}$ (1%, 5%, 10% do desvio padrão dos dados limpos). O mesmo ruído é aplicado às observações de f^* (via $\mathcal{L}_{f\text{-obs}}$) e às observações interiores de u (via $\mathcal{L}_{u\text{-obs}}$).

Questões de Pesquisa

1. A PINN mantém $E_f^{L^2} < 0.05$ para $\beta = 0.05$?
2. Existe limiar β_{crit} acima do qual a identificação colapsa ($E_f^{L^2} > 0.3$)?
3. A regularização $\mathcal{L}_{\text{reg}}$ atua como filtro implícito para o ruído de alta frequência em f_{NN}?

4 Análise Comparativa dos Experimentos

Tabela 1: Definição formal dos experimentos.

Exp.	$f^*(x,t)$	$u^*(x,t)$	Ruído	Dificuldade
1	$\sin(\pi x)e^{-t}$	(4)	Não	Baixa
2	$(\sin(\pi x) + 0.5\sin(2\pi x))e^{-2t}$	Superposição modal	Não	Média
3	Derivado de u^* periódico	$0.05\sin(\pi x)(1 - \cos(2\pi t))$	Não	Média
4	Derivado de u^* saturação	$0.1\sin(\pi x)(1 - e^{-2t})$	Não	Média-Alta
5	$\sin(\pi x)e^{-t}$ (+ ruído)	Igual ao Exp. 1	Sim	Alta

Tabela 2: Aspecto científico central de cada experimento.

Exp.	Aspecto central
1	Validação baseline do método
2	Investigação de estrutura espacial rica
3	Estudo de oscilação temporal
4	Análise de mudança de regime
5	Avaliação de estabilidade sob ruído

4.1 Condição de Identificabilidade

Teorema 4.1 (Condição Necessária de Identificabilidade [9, 10, 29]). *Seja $f^* \in L^2(Q_T)$ o termo fonte verdadeiro e $\mathcal{D}$ o conjunto de observações. Para que f^* seja recuperável a partir de $\mathcal{D}$, é necessário que:*

1. *$T > 0$ suficientemente grande (informação temporal suficiente);*
2. *As observações de u em $\mathcal{D}$ não sejam todas nulas;*
3. *O conjunto $\{u_{\text{obs}}(x_i, t_j)\}$ resolva a degenerescência de escala $(u, f) \mapsto (ku, kf)$, i.e., $\mathcal{D}$ contenha pontos interiores com $u^*(x_i, t_j) \neq 0$.*

Observação 4.1 (Papel das Observações de u na Loss). *A condição 3 acima é implementada computacionalmente pelo termo $\mathcal{L}_{u\text{-}obs}$ em (13), com $N_u = 3\,600$ pontos em grade uniforme interior. Esta escolha garante que* toda fatia temporal *$t = t_j$ contenha pelo menos 60 observações de u^* com magnitude não nula, ancorando tanto a escala quanto a forma espaço-temporal da solução predita.*

5 Implementação Computacional

5.1 Estrutura do Projeto

O código é organizado nos seguintes módulos principais:

Arquivo	Responsabilidade
`analytical_solutions.py`	Pares (u^*, f^*) verificados para cada experimento
`synthetic_data_generator.py`	Geração de todos os datasets de treinamento/teste
`pinn_architecture.py`	Redes $\mathcal{N}_u$, $\mathcal{N}_f$ e função de perda
`pinn_trainer.py`	Loop de treinamento, logging, checkpointing
`pinn_visualization.py`	Geração de GIFs e gráficos de análise
`pinn_main.py`	Ponto de entrada; leitura de `configs/*.json`
`configs/exp{1..5}.json`	Hiperparâmetros por experimento

5.2 Verificação das Soluções Analíticas

Antes de qualquer treinamento, todos os pares (u^*, f^*) são verificados numericamente por diferenças finitas centradas de segunda ordem [26, 27]:

$$D_t u^* = \frac{u^*(x_i, t_j + \delta t) - u^*(x_i, t_j - \delta t)}{2\delta t}, \quad D_{xx} u^* = \frac{u^*(x_i + \delta x, t_j) - 2u^*(x_i, t_j) + u^*(x_i - \delta x, t_j)}{\delta x^2}$$

$$\max_{(x_i, t_j) \in Q_T} |D_t u^*(x_i, t_j) - \alpha\, D_{xx} u^*(x_i, t_j) - f^*(x_i, t_j)| < 10^{-4} \tag{28}$$

com $\delta t = \delta x = 10^{-5}$. Esta verificação é executada automaticamente pelo módulo `analytical_solutions.py`.

5.3 Hiperparâmetros de Treinamento

Listing 2: Configuração do Experimento 1 (excerpt de exp1_baseline.json)

```
{
  "model": {
    "net_u": { "layers": [2,50,50,50,50,1], "activation": "tanh" },
    "net_f": { "layers": [2,50,50,50,1],    "activation": "tanh" }
  },
  "training": {
    "n_steps": 8000,
    "batch_size": 1000,
    "loss_weights": {
      "bc": 100.0, "pde": 10.0, "reg": 1e-4,
      "u_obs": 100.0, "f_obs": 50.0
    },
    "optimizer": { "type": "adam", "lr": 0.001 },
    "scheduler": { "type": "step", "step_size": 2000, "gamma": 0.9 }
  },
  "data": {
    "N_train_x": 150, "N_train_t": 150,
    "N_bc": 1000, "N_f_obs": 200,
    "N_obs_ux": 60,  "N_obs_ut": 60
  }
}
```

Referências

[1] Maziar Raissi, Paris Perdikaris e George Em Karniadakis. "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations". Em: *Journal of Computational Physics* 378 (2019), pp. 686–707. DOI: 10.1016/j.jcp.2018.10.045.

[2] George Em Karniadakis et al. "Physics-informed machine learning". Em: *Nature Reviews Physics* 3.6 (2021), pp. 422–440. DOI: 10.1038/s42254-021-00314-5.

[3] Lawrence C. Evans. *Partial Differential Equations*. 2ª ed. Providence, RI: American Mathematical Society, 2010.

[4] Haim Brezis. *Functional Analysis, Sobolev Spaces and Partial Differential Equations*. New York: Springer, 2011. DOI: 10.1007/978-0-387-70914-7.

[5] Jacques-Louis Lions e Enrico Magenes. *Non-Homogeneous Boundary Value Problems and Applications*. Vol. 1. Berlin: Springer, 1972. DOI: 10.1007/978-3-642-65161-8.

[6] Walter A. Strauss. *Partial Differential Equations: An Introduction*. 2ª ed. Hoboken, NJ: Wiley, 2008.

[7] Sandro Salsa. *Partial Differential Equations in Action: From Modelling to Theory*. Milan: Springer, 2008. DOI: 10.1007/978-88-470-0752-9.

[8] Earl A. Coddington e Norman Levinson. *Theory of Ordinary Differential Equations*. New York: McGraw-Hill, 1955.

[9] Victor Isakov. *Inverse Problems for Partial Differential Equations*. 3ª ed. Cham: Springer, 2017. DOI: 10.1007/978-3-319-51658-5.

[10] Alemdar H. Hasanov e Vladimir G. Romanov. *Introduction to Inverse Problems for Differential Equations*. Cham: Springer, 2017. DOI: 10.1007/978-3-319-62797-7.

[11] Alexandre M. Tartakovsky et al. "Physics-Informed Deep Neural Networks for Learning Parameters and Constitutive Relationships in Subsurface Flow Problems". Em: *Water Resources Research* 56.5 (2020), e2019WR026731. DOI: 10.1029/2019WR026731.

[12] Ian Goodfellow, Yoshua Bengio e Aaron Courville. *Deep Learning*. Cambridge, MA: MIT Press, 2016.

[13] Kurt Hornik, Maxwell Stinchcombe e Halbert White. "Multilayer feedforward networks are universal approximators". Em: *Neural Networks* 2.5 (1989), pp. 359–366. DOI: 10.1016/0893-6080(89)90020-8.

[14] George Cybenko. "Approximation by superpositions of a sigmoidal function". Em: *Mathematics of Control, Signals and Systems* 2.4 (1989), pp. 303–314. DOI: 10.1007/BF02551274.

[15] Adam Paszke et al. "PyTorch: An Imperative Style, High-Performance Deep Learning Library". Em: *Advances in Neural Information Processing Systems*. Vol. 32. Curran Associates, Inc., 2019.

[16] Atılım Güneş Baydin et al. "Automatic differentiation in machine learning: a survey". Em: *Journal of Machine Learning Research* 18.153 (2018), pp. 1–43.

[17] Isaac E. Lagaris, Aristidis Likas e Dimitrios I. Fotiadis. "Artificial neural networks for solving ordinary and partial differential equations". Em: *IEEE Transactions on Neural Networks* 9.5 (1998), pp. 987–1000. DOI: 10.1109/72.712178.

[18] Salvatore Cuomo et al. "Scientific Machine Learning Through Physics-Informed Neural Networks: Where We Are and What's Next". Em: *Journal of Scientific Computing* 92.3 (2022), p. 88. DOI: 10.1007/s10915-022-01939-z.

[19] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.

[20] Lu Lu et al. "DeepXDE: A deep learning library for solving differential equations". Em: *SIAM Review* 63.1 (2021), pp. 208–228. DOI: 10.1137/19M1274067.

[21] Heinz W. Engl, Martin Hanke e Andreas Neubauer. *Regularization of Inverse Problems*. Dordrecht: Kluwer Academic Publishers, 1996. DOI: 10.1007/978-94-009-1740-8.

[22] Sifan Wang, Yujun Teng e Paris Perdikaris. "Understanding and mitigating gradient flow pathologies in physics-informed neural networks". Em: *SIAM Journal on Scientific Computing* 43.5 (2021), A3055–A3081. DOI: 10.1137/20M1318043.

[23] Levi D. McClenny e Ulisses M. Braga-Neto. "Self-adaptive physics-informed neural networks". Em: *Journal of Computational Physics* 474 (2023), p. 111722. DOI: 10.1016/j.jcp.2022.111722.

[24] Diederik P. Kingma e Jimmy Ba. "Adam: A Method for Stochastic Optimization". Em: (2015). arXiv: 1412.6980.

[25] Siddhartha Mishra e Roberto Molinaro. "Estimates on the generalization error of physics-informed neural networks for approximating PDEs". Em: *IMA Journal of Numerical Analysis* 43.1 (2022), pp. 1–43. DOI: 10.1093/imanum/drab032.

[26] Patrick J. Roache. "Code Verification by the Method of Manufactured Solutions". Em: *Journal of Fluids Engineering* 124.1 (2002), pp. 4–10. DOI: 10.1115/1.1436090.

[27] Kambiz Salari e Patrick Knupp. *Code Verification by the Method of Manufactured Solutions*. Rel. técn. SAND2000-1444. Albuquerque, NM: Sandia National Laboratories, 2000. DOI: 10.2172/759450.

[28] Jari Kaipio e Erkki Somersalo. *Statistical and Computational Inverse Problems*. New York: Springer, 2005. DOI: 10.1007/b138659.

[29] John R. Cannon. *The One-Dimensional Heat Equation*. Cambridge: Cambridge University Press, 1984. DOI: 10.1017/CBO9781139086967.

[30] Jacques Hadamard. "Sur les problèmes aux dérivées partielles et leur signification physique". Em: *Princeton University Bulletin* 13 (1902), pp. 49–52.

[31] Andrey Nikolayevich Tikhonov. "On the stability of inverse problems". Em: *Doklady Akademii Nauk SSSR* 39.5 (1943), pp. 195–198.

[32] Maziar Raissi, Paris Perdikaris e George Em Karniadakis. "Physics Informed Deep Learning (Part II): Data-driven Discovery of Nonlinear Partial Differential Equations". Em: *arXiv preprint* (2017). arXiv: 1711.10566.

A Teoremas de Existência Detalhados

A.1 Problema Direto – Lions–Magenes

Teorema A.1 (Lions–Magenes [5, 4]). *Seja $V = H_0^1(\Omega)$, $H = L^2(\Omega)$ e a forma bilinear*

$$a(u,v) = \alpha \int_\Omega u_x\, v_x\, dx, \qquad u, v \in V.$$

Esta forma é:

- ***Coerciva:*** $a(v,v) \geq \alpha \, \|v_x\|_{L^2}^2 \geq \alpha C_P^{-2} \, \|v\|_{H^1}^2$ *(desigualdade de Poincaré com constante C_P);*
- ***Contínua:*** $|a(u,v)| \leq \alpha \, \|u\|_{H^1} \, \|v\|_{H^1}$.

Então, para $f \in L^2(0,T;\, V')$ e $u_0 = 0 \in H$, existe única solução fraca $u \in L^2(0,T;\, V) \cap C([0,T];\, H)$ de (2).

A.2 Caráter Mal-Posto do Problema Inverso

Teorema A.2 (Compacidade de $\mathcal{S}$ e Mal-Postura [9, 21, 30]). *O operador $\mathcal{S} : L^2(Q_T) \to L^2(Q_T)$ é compacto. Consequentemente, o problema inverso de recuperar f a partir de $\mathcal{S}(f)|_{\mathcal{D}}$ é* ***mal-posto*** *no sentido de Hadamard: a inversa $\mathcal{S}^{-1}$ não é contínua, e pequenas perturbações nos dados podem causar grandes desvios em f.*

Este é o fundamento matemático [28, 31, 21, 32] que justifica:

1. O uso do termo de regularização $\mathcal{L}_{\text{reg}}$ em (9) (análogo à regularização de Tikhonov [31, 21]);
2. A necessidade de observações ricas de u (via $\mathcal{L}_{u\text{-obs}}$) para estabilizar a inversão [11];
3. A sensibilidade ao ruído estudada no Experimento 5 [28].